


ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ

ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ



# ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

1<sup>η</sup> ΕΡΓΑΣΙΑ CLASSIFICATION

ΦΟΙΤΗΤΕΣ:

Κοκκινογένης Βασίλειος | ics21146

Κούβαρος Ιωάννης | iis22078

Μάνο Αστέριος-Πάρης | ics22088

Δεκέμβριος, 2024

## Πίνακας Περιεχομένων

|                                                             |    |
|-------------------------------------------------------------|----|
| Εισαγωγή.....                                               | 2  |
| Θεωρητικό Υπόβαθρο .....                                    | 3  |
| Μέθοδοι και Υπερπαράμετροι.....                             | 3  |
| Εκπαίδευση και Αξιολόγηση Μοντέλων .....                    | 3  |
| Μετρικές Αξιολόγησης .....                                  | 5  |
| Πειραματικά Αποτελέσματα .....                              | 6  |
| Σύνολο Συγκριτικών Αποτελεσμάτων και Μετρικές Μοντέλων..... | 10 |
| Συμπεράσματα.....                                           | 13 |

## Πίνακας Γραφημάτων και λοιπών Σχημάτων

|                                                                                                                                                            |    |
|------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| <b>Διάγραμμα 1:</b> Αριθμός υγιών (πράσινο) και χρεοκοπημένων (κόκκινο) επιχειρήσεων των αρχικών δεδομένων από το 2006 έως το 2009.....                    | 6  |
| <b>Διάγραμμα 2:</b> Ελάχιστη, μέγιστη και μέση τιμή του δείκτη Λειτουργικά Αποτελέσματα προς Συνολική Ενεργητική (ROA) για υγιείς επιχειρήσεις.....        | 7  |
| <b>Διάγραμμα 3:</b> Ελάχιστη, μέγιστη και μέση τιμή του δείκτη Λειτουργικά Αποτελέσματα προς Συνολική Ενεργητική (ROA) για χρεωκοπημένες επιχειρήσεις..... | 8  |
| <b>Διάγραμμα 4:</b> Confusion Matrix για το μοντέλο SVM στο train και test σετ αντίστοιχα.....                                                             | 9  |
| <b>Διάγραμμα 5:</b> F1-score των classifiers σε train και test set .....                                                                                   | 11 |
| <b>Διάγραμμα 6:</b> Σύγκριση classifiers με βάση τη ανάκληση (Recall) των εταιριών της κλάσης 0 δηλαδή αυτών που θα κηρύξουν πτώχευση.....                 | 12 |
| <b>Διάγραμμα 7:</b> Σύγκριση classifiers με βάση τη ανάκληση (Recall) των εταιριών της κλάσης 1 δηλαδή αυτών που θα παραμείνουν υγιείς. ....               | 12 |

## Εισαγωγή

Η ανάλυση δεδομένων και η εφαρμογή μοντέλων ταξινόμησης για την πρόβλεψη επιχειρηματικών αποτελεσμάτων αποτελεί κρίσιμη διαδικασία στη σύγχρονη οικονομία. Στο πλαίσιο αυτής της μελέτης, στόχος είναι να αξιολογηθούν διάφοροι αλγόριθμοι ταξινόμησης (classifiers) για την πρόβλεψη των εταιρειών που πρόκειται να πτωχεύσουν. Τα δεδομένα που χρησιμοποιούνται παρέχονται από επίσημο οργανισμό και περιλαμβάνουν οικονομικούς δείκτες και μετρικές που αφορούν τα αποθέματα, το προσωπικό κ.α. Το πρόβλημα είναι ζωτικής σημασίας καθώς η έγκαιρη αναγνώριση οικονομικά ασθενών επιχειρήσεων μπορεί να συμβάλει στην αποτελεσματικότερη διαχείριση κινδύνου από χρηματοπιστωτικά ιδρύματα, επενδυτές και άλλους φορείς.

Η μελέτη περιλαμβάνει την εφαρμογή αλγορίθμων ταξινόμησης, όπως Logistic Regression, Decision Trees, Random Forests, και Support Vector Machines, μεταξύ άλλων σε προγραμματιστικό επίπεδο στη γλώσσα python. Στόχος είναι η σύγκριση των μοντέλων αυτών βάσει μετρικών αξιολόγησης όπως Accuracy, Recall και ROC-AUC κ.α. Ιδιαίτερη έμφαση θα δοθεί στην ικανότητα των μοντέλων να εντοπίζουν εταιρείες που βρίσκονται σε κίνδυνο χρεοκοπίας, με ελάχιστο όριο επιτυχίας 60%, ενώ ταυτόχρονα πρέπει να διατηρούν υψηλή ακρίβεια τουλάχιστον άνω του 70% στην ταξινόμηση των υγιών επιχειρήσεων, αυτών δηλαδή που δεν θα πτωχεύσουν.

Η μελέτη αυτή δεν περιορίζεται απλώς στη δημιουργία ενός τεχνικά αποδοτικού μοντέλου. Στόχος μας είναι να παρέχουμε μία πλήρως ερμηνεύσιμη και τεκμηριωμένη προσέγγιση, η οποία να ενισχύει την εμπιστοσύνη των ενδιαφερόμενων φορέων στη χρήση τεχνικών μηχανικής μάθησης για την επίλυση πραγματικών επιχειρηματικών προβλημάτων. Μέσω της ανάλυσης των αποτελεσμάτων και της κατάλληλης οπτικοποίησης, θα καταλήξουμε στο πλέον αποδοτικό μοντέλο, ικανό να ανταποκριθεί στις απαιτήσεις που τίθενται από τα δεδομένα και τις συνθήκες του προβλήματος.

## Θεωρητικό Υπόβαθρο

### Μέθοδοι και Υπερπαράμετροι

Στην μελέτη εφαρμόστηκαν διάφορες μέθοδοι μηχανικής μάθησης για την ταξινόμηση επιχειρήσεων σε υγιείς και χρεοκοπημένες, χρησιμοποιώντας ένα σύνολο δεδομένων χρηματοοικονομικών δεικτών. Το data set ελέγχθηκε για την ορθότητά του και στη συνέχεια χρησιμοποιήθηκε ως είσοδο στον κώδικα. Για τον διαχωρισμό των επιχειρήσεων που πρόκειται να πτωχεύσουν και αυτών που παραμένουν υγιείς ορίζονται οι παρακάτω 2 κλάσεις:

**Κλάση 0 :** εταιρίες που πρόκειται να πτωχεύσουν (κηρύζουν χρεοκοπία)

**Κλάση 1 :** εταιρίες που πρόκειται να παραμείνουν υγιείς

Συγκεκριμένα, για τη σωστή απόδοση των classifiers εφαρμόστηκε αρχικά Ανίχνευση Ελλείψεων όπου ελέγχθηκαν οι στήλες A έως H, που περιέχουν τους δείκτες απόδοσης των εταιριών, για τυχόν μηδενικές τιμές που αντιπροσωπεύουν ελλείψεις δεδομένων. Έπειτα, χρησιμοποιήθηκε η τεχνική Min-Max για την κανονικοποίηση των τιμών των δεικτών, ώστε να περιοριστούν στο διάστημα  $[0, 1]$ . Ακόμη, χρησιμοποιήθηκε η τεχνική Standard Scaling για να μετατραπούν τα χαρακτηριστικά σε τυποποιημένη μορφή και να βελτιωθεί η απόδοση μοντέλων όπως λ.χ. Logistic Regression και SVM. Το Standard Scaling βοήθησε ώστε τα χαρακτηριστικά να βρίσκονται στην ίδια κλίμακα και να εξαλειφθεί η επίδραση των διαφορετικών μονάδων μέτρησης. Εφαρμόστηκε τυχαία δειγματοληψία για τη διατήρηση της αναλογίας 3 προς 1 μεταξύ των υγιών και των χρεοκοπημένων εταιρειών. Σε περιπτώσεις όπου υπήρχε υπερβολική ανισορροπία, επιλέχθηκαν τυχαία υγιείς επιχειρήσεις για ισορρόπηση.

### Εκπαίδευση και Αξιολόγηση Μοντέλων

#### Stratified K-Fold Cross-Validation

Για να εξασφαλιστεί αξιόπιστη εκτίμηση της απόδοσης, χρησιμοποιήθηκε cross validation με 4 folds, όπου δόθηκε προσοχή ώστε να διατηρηθεί η αναλογία των κλάσεων (υγιείς, χρεοκοπημένες) σε κάθε fold.

#### Classifiers

Όσον αφορά τα μοντέλα ταξινόμησης που χρησιμοποιήθηκαν, παρακάτω παρατίθεται οι υπερπαράμετροι:

**Linear Discriminant Analysis (LDA):** Αποτελεί μια απλή γραμμική μέθοδος που υποθέτει κανονικότητα στη διασπορά των δεδομένων, οπότε δεν χρησιμοποιείται κάποια υπερπαράμετρος.

**Logistic Regression:** Προσαρμόστηκε με την υπερπαράμετρο `max_iter = 1000` για επαρκή σύγκλιση κατά την εκπαίδευση.

**Decision Tree:** Μη γραμμική μέθοδος που χωρίζει τα δεδομένα βάσει κανόνων ανάλυσης χαρακτηριστικών.

**Random Forest:** Στο συγκεκριμένο μοντέλο συνδυάζονται πολλά δέντρα απόφασης για την αύξηση της ακρίβειας και αντοχής στο θόρυβο. Χρησιμοποιήθηκε η υπερπαράμετρος `n_estimators = 100`, που δηλώνει τον αριθμό των δέντρων στο δάσος.

**k-Nearest Neighbors (k-NN):** Κατηγοριοποίηση με βάση την εγγύτητα στα δεδομένα εκπαίδευσης. Χρησιμοποιήθηκε η υπερπαράμετρος `n_neighbors` που δηλώνει τον αριθμό των γειτόνων με την προεπιλεγμένη (by default) τιμή 5.

**Naive Bayes:** Το μοντέλο υποθέτει ανεξαρτησία μεταξύ των χαρακτηριστικών και απλοποιεί την υπολογιστική πολυπλοκότητα. Δεν χρησιμοποιήθηκε κάποια υπερπαράμετρος.

**Support Vector Machine (SVM):** Χρησιμοποιήθηκε γραμμικός πυρήνας `kernel = 'linear'` για να καθοριστεί πως το όριο απόφασης (decision boundary) θα είναι μια ευθεία γραμμή. Χρησιμοποιήθηκε επιπλέον η προεπιλεγμένη τιμή της υπερπαραμέτρου `C = 1.0` για τη ρύθμιση της ισορροπίας μεταξύ ορθότητας και πολυπλοκότητας.

### **Gradient Boosting:**

Το μοντέλο Gradient Boosting αποτελεί μία μέθοδο με συχνή εφαρμογή σε προβλήματα παλινδρόμησης και ταξινόμησης και βασίζεται στην λειτουργία των δέντρων απόφασης. Αξιοποιεί πολλαπλούς αλγορίθμους εκμάθησης προκειμένου να αποδώσει την καλύτερη προγνωστική δυνατότητα, με την μορφή ενισχυμένου δένδρου απόφασης (BDT). Η κυρίαρχη ιδέα πίσω από αυτόν τον αλγόριθμο είναι η κατάλληλη κατασκευή των πρωταρχικών μοντέλων που χρησιμοποιεί, έτσι ώστε να είναι μέγιστα συσχετισμένα με την αρνητική κλίση (gradient). Το συγκεκριμένο μοντέλο που επιλέχθηκε επικεντρώνεται στη διαδοχική διόρθωση των σφαλμάτων των προηγούμενων δέντρων. Χρησιμοποιήθηκαν οι υπερπαράμετροι `learning_rate = 0.1` και `n_estimators = 100`, όπου το `learning_rate` υποδεικνύει τον ρυθμό μάθησης.

Στα μοντέλα LR, Decision Tree, Random Forest, SVM και Gradient Boosting χρησιμοποιήθηκε η υπερπαραμέτρος `random_state = 42`, η οποία εξασφαλίζει την επαναληψιμότητα των δεδομένων.

## Μετρικές Αξιολόγησης

Παρακάτω παρατίθενται οι μετρικές που χρησιμοποιήθηκαν καθώς και αυτές που υπολογίστηκαν:

**Accuracy:** Ποσοστό σωστών προβλέψεων σε σχέση με το σύνολο των εταιριών.

**Precision:** Η ακρίβεια στις θετικές προβλέψεις(κλάση ο) δηλαδή στις εταιρείες που πτωχεύουν.

**Recall (Sensitivity):** Ικανότητα ανίχνευσης όλων των πτωχευμένων εταιρειών (True Positives).

**F1 Score:** Αποτελεί συνδυασμό του Precision και του Recall.

**ROC-AUC:** Δείχνει τη συνολική απόδοση του μοντέλου.

Για την αξιολόγηση των μοντέλων επιλέχθηκαν οι εξής δύο επιπλέον μετρικές:

**Cohen's KAPPA:** Το Cohen's Kappa είναι ένας δείκτης που χρησιμοποιείται για να μετρήσει τη συμφωνία (ή συνέπεια) μεταξύ δύο μοντέλων, λαμβάνοντας υπόψη την πιθανότητα να συμφωνήσουν τυχαία. Είναι ιδιαίτερα χρήσιμος για δεδομένα που ανήκουν σε κατηγορίες. Η τιμή του Cohen's Kappa κυμαίνεται από -1 έως +1 με το +1 να υποδηλώνει τέλεια συμφωνία μεταξύ των παρατηρητών, το 0 καμία συμφωνία πέρα από αυτή που θα μπορούσε να συμβεί τυχαία και το -1 απόλυτη ασυμφωνία. Είναι συχνά πιο αξιόπιστος από τον απλό υπολογισμό της συμφωνίας σε ποσοστά, καθώς το k λαμβάνει υπόψη τη δυνατότητα η συμφωνία να έχει συμβεί τυχαία. Η συνάρτηση υπολογισμού του Cohens's Kappa που χρησιμοποιήθηκε ήταν η εξής:

$$K = \frac{2 * (TP * TN - FN * FP)}{((TP + FP) * (FP + TN)) + ((TP + FN) * (FN + TN))}$$

**MCC:** Ο Matthews Correlation Coefficient είναι ένας στατιστικός δείκτης που μετρά την ποιότητα της δυαδικής ταξινόμησης, λαμβάνοντας υπόψη όλες τις κατηγορίες του correlation matrix: τα true, false positives και negatives αποτελέσματα. Ο υπολογισμός του γίνεται μέσω ενός μαθηματικού τύπου που συνδυάζει αυτές τις τιμές, αποδίδοντας έναν αριθμό μεταξύ -1 και 1. Τιμές κοντά στο 1 υποδεικνύουν τέλεια πρόβλεψη, το 0 δηλώνει τυχαία πρόβλεψη, ενώ το -1 σημαίνει πλήρως εσφαλμένη. Ο MCC είναι ιδιαίτερα χρήσιμος για την αξιολόγηση classifiers σε

ανισόρροπα σύνολα δεδομένων, καθιστώντας τον έναν από τους πιο αξιόπιστους δείκτες απόδοσης μοντέλων. Ο τύπος του MCC που χρησιμοποιήθηκε ήταν ο εξής:

$$MCC = (TP*TN-FP*FN) / \sqrt{((TP+FP)(TP+FN)(TN+FP)(TN+FN))}$$

## Πειραματικά Αποτελέσματα


Παρακάτω παρουσιάζουμε ενδεικτικά αποτελέσματα από κάθε cell κώδικα και γραφήματα, πίνακες από τη σύγκριση των μοντέλων μετά από επεξεργασία στο excel.

### 2<sup>ο</sup> α Ερώτημα: Αριθμός υγιών και χρεοκοπημένων επιχειρήσεων ανά έτος



**Διάγραμμα 1:** Αριθμός υγιών (πράσινο) και χρεοκοπημένων (κόκκινο) επιχειρήσεων των αρχικών δεδομένων από το 2006 έως το 2009


2<sup>ο</sup> β Ερώτημα: Min, Max, Average τιμή για κάθε δείκτη των υγιών και χρεοκοπημένων εταιριών



**Διάγραμμα 2:** Ελάχιστη, μέγιστη και μέση τιμή του δείκτη Λειτουργικά Αποτελέσματα προς Συνολική Ενεργητική (ROA) για υγιείς επιχειρήσεις

Στο διάγραμμα 2 η ελάχιστη τιμή απεικονίζεται με πράσινο χρώμα και είναι περίπου -0.6, υποδεικνύοντας ότι κάποιες επιχειρήσεις παρουσίασαν σημαντική αρνητική απόδοση, ενώ η μέγιστη τιμή με κόκκινο χρώμα φτάνει περίπου 0.5, δείχνοντας ότι ορισμένες επιχειρήσεις κατέγραψαν υψηλή απόδοση. Η μέση τιμή με μπλε χρώμα κυμαίνεται κοντά στο 0.05, υποδεικνύοντας ότι συνολικά οι υγιείς επιχειρήσεις είχαν μικρή θετική απόδοση.






**Διάγραμμα 3:** Ελάχιστη, μέγιστη και μέση τιμή του δείκτη Λειτουργικά Αποτελέσματα προς Συνολική Ενεργητική (ROA) για χρεωκοπημένες επιχειρήσεις

Στο διάγραμμα 3 η ελάχιστη τιμή απεικονίζεται με πράσινο χρώμα και φτάνει περίπου το -0.6, δείχνοντας ότι αρκετές χρεωκοπημένες επιχειρήσεις είχαν σημαντικά αρνητική απόδοση. Η μέγιστη τιμή του δείκτη, σε κόκκινο χρώμα, αγγίζει περίπου 0.45, υποδεικνύοντας ότι κάποιες επιχειρήσεις, παρόλο που χρεωκόπησαν, εμφάνισαν θετική απόδοση σε κάποια περίοδο. Η μέση τιμή με μπλε χρώμα, είναι ελαφρώς κάτω από το μηδέν, κάτι που επιβεβαιώνει ότι, κατά μέσο όρο, οι χρεωκοπημένες επιχειρήσεις παρουσίασαν χαμηλές έως αρνητικές αποδόσεις.

## 8° / 9° Ερώτημα: Confusion Matrixes



**Διάγραμμα 4:** Confusion Matrix για το μοντέλο SVM στο train και test σετ αντίστοιχα

Στο train set το μοντέλο SVM προβλέπει τον αριθμό των υγιών επιχειρήσεων (κλάση 1) πολύ καλά με 532 σωστές προβλέψεις και μόνο 26 λάθος. Η κλάση των χρεοκοπημένων επιχειρήσεων (κλάση 0) είναι πιο δύσκολη καθώς παρατηρούνται 63 σωστές προβλέψεις αλλά 123 λάθος προβλέψεις, υποδεικνύοντας πρόβλημα ανισορροπίας των δεδομένων.


Στο test set παρατηρείται παρόμοια τάση. Η κλάση των υγιών επιχειρήσεων προβλέπεται με ακρίβεια (2465 σωστές) ενώ υπάρχουν 152 λάθος προβλέψεις. Η κλάση των χρεοκοπημένων επιχειρήσεων έχει χαμηλότερη απόδοση με μόλις 19 σωστές προβλέψεις και 43 λάθος, κάτι που δείχνει δυσκολία γενίκευσης στην κλάση 1.

## Σύνολο Συγκριτικών Αποτελεσμάτων και Μετρικές Μοντέλων

Ο παρακάτω πίνακας παρουσιάζει τις επιδόσεις των classifiers σε test και train sets, καθώς και το μέγιστο της επίδοσης τους (F1 score). Συνολικά, συγκρίθηκαν οκτώ διαφορετικά μοντέλα:


1. Decision Tree: Παρουσιάζει Overfitting (1 στο Train και 0.903 στο Test)
2. Gradient Boosting: Πολύ καλή γενίκευση (Test: 0.956, Train: 0.969)
3. k-Nearest Neighbors: Καλή συμπεριφορά και με Test 0.940 και με Train: 0.906.
4. Linear Discriminant Analysis: Χαμηλότερη απόδοση στο Train (0.888), αλλά καλή στο Test (0.959).
5. Logistic Regression και Naive Bayes: Παρουσιάζουν ισορροπημένη συμπεριφορά, αν και οι επιδόσεις τους κυμαίνονται χαμηλότερα από άλλους αλγόριθμους.
6. Random Forest: Παρουσιάζει overfitting.
7. Support Vector Machine: Υψηλή ακρίβεια στο Test (0.971), αλλά χαμηλή στο Train (0.887).

| Models                       | Test  | Train |
|------------------------------|-------|-------|
| Decision Tree                | 0.903 | 1.000 |
| Gradient Boosting            | 0.956 | 0.969 |
| k-Nearest Neighbors          | 0.940 | 0.906 |
| Linear Discriminant Analysis | 0.959 | 0.888 |
| Logistic Regression          | 0.958 | 0.886 |
| Naive Bayes                  | 0.937 | 0.869 |
| Random Forest                | 0.963 | 1.000 |
| Support Vector Machine       | 0.971 | 0.887 |
| <b>Max F1 score</b>          | 0.971 | 1     |




**Διάγραμμα 5:** *F1-score των classifiers σε train και test set*

Ο παραπάνω πίνακας παρουσιάζει τα F1-scores για διάφορους αλγορίθμους ταξινόμησης (classifiers) που αξιολογήθηκαν σε δύο σύνολα δεδομένων: Train (εκπαίδευσης) και Test (δοκιμής). Ο κατακόρυφος άξονας  $y$  αντιπροσωπεύει τα F1-scores, με τιμές από 0.800 έως 1.050. Ο οριζόντιος άξονας  $x$  περιλαμβάνει τους classifiers. Οι μπλε μπάρες αναπαριστούν τις επιδόσεις στο Test σύνολο, ενώ οι κόκκινες τις επιδόσεις στο Train σύνολο.



**Διάγραμμα 6:** Σύγκριση classifiers με βάση τη ανάκληση (Recall) των εταιριών της κλάσης 0 δηλαδή αυτών που θα κηρύξουν πτώχευση.

Στο διάγραμμα παρατηρείται ότι όλες οι εξεταζόμενες μέθοδοι έχουν πολύ υψηλά επίπεδα recall (πάνω από 98.40%), γεγονός που υποδηλώνει την καταλληλότητά τους για το υπό μελέτη πρόβλημα. Παρόλα αυτά, ο classifier Gradient Boosting υπερέχει και αποτελεί την καλύτερη επιλογή για τη βέλτιστη θετική ανάκληση (98.70%).



**Διάγραμμα 7:** Σύγκριση classifiers με βάση τη ανάκληση (Recall) των εταιριών της κλάσης 1 δηλαδή αυτών που θα παραμείνουν υγιείς.

Για τον υπολογισμό της μετρικής αυτής χρησιμοποιήθηκε ο τύπος:  $TN/(TN+FP)$ , όπου TN είναι οι εταιρίες που δεν πτώχευσαν και αναγνωρίστηκαν σωστά ενώ FP είναι οι εταιρίες που δεν πτώχευσαν αλλά αναγνωρίστηκαν ως πτωχευμένες. Η Support Vector Machine σημειώνει τη μεγαλύτερη τιμή, φτάνοντας το 13.09%.

## Συμπεράσματα

Η μελέτη που διεξήχθη είχε ως θέμα την πρόβλεψη εταιρειών που ενδέχεται να κηρύξουν πτώχευση, με χρήση τεχνικών μηχανικής μάθησης και δεδομένα οικονομικών δεικτών. Εφαρμόστηκαν διάφορα μοντέλα ταξινόμησης (classifiers), όπως Logistic Regression, Decision Trees, Random Forests και Support Vector Machines. Αξιολογήθηκε η απόδοση αυτών των μοντέλων με βάση μετρικές, όπως η ακρίβεια, η ανάκληση και το F1-score.

Η ανάλυση έδειξε ότι το μοντέλο Gradient Boosting παρουσίασε την καλύτερη συνολική απόδοση, πετυχαίνοντας υψηλή ανάκληση (98.70%), γεγονός που το καθιστά εξαιρετικό στην αναγνώριση επιχειρήσεων που θα πτωχεύσουν. Παρόμοια, τα μοντέλα Random Forest και K-Nearest Neighbors πλησίασαν αυτήν την επίδοση. Ωστόσο, η αρνητική ανάκληση, δηλαδή η ικανότητα πρόβλεψης εταιρειών που δεν θα πτωχεύσουν, ήταν γενικά χαμηλή στο σύνολο των μοντέλων, με το Support Vector Machine να σημειώνει τη μέγιστη τιμή με μόλις 13.09%.

Για τη βελτίωση της ακρίβειας, προτείνεται η προσθήκη περισσότερων χαρακτηριστικών, η βελτιστοποίηση των παραμέτρων και η χρήση τεχνικών ensemble για την αξιοποίηση των δυνατών σημείων διαφορετικών μοντέλων και την μείωση των αδυναμιών ενός μεμονωμένου μοντέλου, επιτυγχάνοντας τελικά βέλτιστα συνολικά αποτελέσματα.

Η μελέτη αναδεικνύει τη σημασία της έγκαιρης πρόβλεψης πτωχεύσεων στη σύγχρονη παγκόσμια οικονομία, όπου οικονομικές κρίσεις, πολιτική αστάθεια και χρηματοοικονομικές αβεβαιότητες καθιστούν τέτοιες τεχνικές απαραίτητες για τη λήψη επιχειρηματικών και επενδυτικών αποφάσεων.

Με βάση τα αποτελέσματα, **δεν υπάρχει μοντέλο που να πληροί και τις δύο προϋποθέσεις ταυτόχρονα**. Το Gradient Boosting είναι το καλύτερο μοντέλο για την πρόβλεψη των εταιρειών που θα πτωχεύσουν, αλλά υστερεί στην αναγνώριση εταιρειών που δεν θα πτωχεύσουν. Το καλύτερο μοντέλο ταξινόμησης με βάση το F1-score είναι το Support Vector Machine (SVM), το οποίο επιτυγχάνει F1-score 0.971 στο σύνολο δοκιμής (test set), αν και εξακολουθεί να απαιτεί βελτιώσεις στην αρνητική ανάκληση για να πληροί πλήρως τις απαιτήσεις της μελέτης.

## Εφαρμογή Τεχνικών Ensemble Learning

**Stacking:** Η χρήση της τεχνικής stacking μπορεί να βοηθήσει στην καλύτερη συνδυασμένη απόδοση διαφορετικών μοντέλων. Το stacking συνδυάζει τα αποτελέσματα πολλών μοντέλων (όπως Logistic Regression, SVM, Random Forest

και Gradient Boosting) χρησιμοποιώντας ένα ενιαίο μοντέλο που μπορεί να βελτιώσει τις προβλέψεις.

**Boosting:** Εφαρμόζοντας μια πιο αυστηρή ρύθμιση του Gradient Boosting (λόγου χάρη μικρότερο learning rate και περισσότερους estimators) μπορεί να επιτευχθεί καλύτερη γενίκευση.

**Bagging (Random Forest):** Ο συνδυασμός πολλών δέντρων απόφασης μέσω τεχνικών όπως το Bagging μπορεί να βοηθήσει στην εξάλειψη των σφαλμάτων από τα μεμονωμένα δέντρα και να μειώσει την αντίδραση στο θόρυβο.

Για τη βελτίωση των αρχικών δεδομένων, μπορεί να γίνει ενίσχυση χαρακτηριστικών (λ.χ. προσθήκη νέων οικονομικών δεικτών), καθώς και εφαρμογή τεχνικών για την εξισορρόπηση των κλάσεων (όπως oversampling ή undersampling) ώστε να βελτιωθεί η απόδοση του μοντέλου σε ανισόρροπα δεδομένα. Ως προς την βελτιστοποίηση των υπερπαραμέτρων, η σωστή ρύθμιση παραμέτρων όπως ο αριθμός δέντρων, το βάθος των δέντρων και ο ρυθμός μάθησης μπορεί να βελτιώσει την ακρίβεια του μοντέλου.