

Μηχανική Μάθηση

2^η Εργασία – Clustering problems

Το πρόβλημα που θα αντιμετωπίσετε αφορά στην αξιολόγηση διαφορετικών συνδυαστικών μοντέλων μείωσης διάστασης του χώρου των μεταβλητών (dimensionality reduction) και συσταδοποίησης (clustering) πάνω σε εικόνες.

Τα δεδομένα που θα χρησιμοποιήσετε αφορούν στο **fashion-mnist** dataset. Πληροφορίες στο ακόλουθο link: https://keras.io/api/datasets/fashion_mnist/.

Για την συγκεκριμένη άσκηση θα παραδώσετε ένα αρχείο σε python στο οποίο θα παρουσιάζετε τις διαφορές στα αποτελέσματα συσταδοποίησης όταν χρησιμοποιώντας ακατέργαστα (raw) δεδομένα και όταν χρησιμοποιούνται σύνθετα περιγραφικά χαρακτηριστικά (features), τα οποία προέκυψαν μέσω τεχνικών dimensionality reduction.

Συνολικά πρέπει να χρησιμοποιήσετε τρεις (3) διαφορετικές τεχνικές dimensionality reduction. Οι δύο (2) εκ των οποίων *πρέπει* να είναι:

1. Principal component analysis.
2. Stacked autoencoder.

3. Factor Analysis
+ παράγραφος ✓

Η τρίτη τεχνική επαφίεται στην επιλογή σας.

Επίσης θα πρέπει να χρησιμοποιήσετε τρεις (3) διαφορετικές τεχνικές clustering. Οι δύο (2) εκ των οποίων πρέπει να είναι:

1. Minibatch kmeans
2. DBSCAN

3. Agglomerative Clustering.
+ παράγραφος ✓

Η τρίτη τεχνική επαφίεται στην επιλογή σας.

Η αξιολόγηση της καταλληλότητας των cluster θα γίνει με χρήση τεσσάρων (4) μετρικών απόδοσης. Οι τρεις (3) εξ' αυτών είναι οι:

1. Calinski–Harabasz index
2. Davies–Bouldin index
3. Silhouette score

4. Adjusted Mutual Information
+ παράγραφος ✓

Η 4^η μετρική είναι της επιλογής σας.

Ο κώδικας που θα παραδώσετε, σε γλώσσα Python, πρέπει να υλοποιεί τα ακόλουθα:

1^η: stacked
autoencoder
2^η: Principal
PCA

1. Θα φορτώνει τα δεδομένα του fashion-mnist.
2. Θα διαχωρίζει τα δεδομένα σε τρία σύνολα: train, validation & test data.
3. Θα τρέχει μια τεχνική dimensionality reduction, πάνω στα train data.

Παρατηρήσεις: α) η αρχιτεκτονική για τον SAE θα καθοριστεί από εσάς. β) Τα NN-based models, κατά την διάρκεια του fit, θα χρειαστούν και τα validation data. γ) Προσοχή: στην SAE αρχιτεκτονικές πρέπει να απομονώσετε το κομμάτι του encoder για να κάνετε το dimensionality reduction.

→ κλάσες: 10

4. Θα τυπώνει τυχαία εικόνες από το dataset (μία από κάθε κλάση) καθώς και τις ανακατασκευασμένες, εφόσον η τεχνική το επιτρέπει.
5. Θα τυπώνει μια γραφική παράσταση, όποια κρίνετε χρήσιμη, για να δείξετε ότι η τεχνική για το dimensionality reduction μάλλον θα δουλέψει
6. Θα χρησιμοποιεί την τεχνική πάνω στα test data και θα τα κωδικοποιεί.
7. Θα χρησιμοποιεί τρεις (3) διαφορετικές τεχνικές clustering για να δημιουργήσει τα αντίστοιχα clusters.
8. Θα υπολογίζει τις τέσσερις (4) μετρικές απόδοσης.
9. Να καταχωρεί σε ένα dataframe (Pandas) σε μια νέα γραμμή τις ακόλουθες πληροφορίες:
 - a. Dimensionality reduction technique name (str). Use "Raw" if no technique was used.
 - b. Clustering algorithm (str).
 - c. Training time for the dim. red. tech. in seconds (double)
 - d. Execution time for the clustering tech. in seconds (double)
 - e. Number of suggested clusters (int)
 - f. Calinski–Harabasz index (double)
 - g. Davies–Bouldin index (double)
 - h. Silhouette score (double)
 - i. The metric of your choice (double)
10. Θα παρουσιάζει ενδεικτικά αποτελέσματα ομαδοποίησης για τυχαίες εικόνες για τέσσερις (4) κατηγορίες (classes) της επιλογής σας.

Γενικές παρατηρήσεις:

1. Τα βήματα 3 έως και 9 θα εκτελεστούν τρεις (3) φορές, όσες δηλαδή και οι τεχνικές μείωσης διάστασης.
2. Οι τεχνικές clustering θα εφαρμοστούν στο test set. Είναι σημαντικά μικρότερο σε πλήθος παρατηρήσεων, άρα θα τρέξει πιο γρήγορα.
3. Η παραπάνω διαδικασία θα επαναληφθεί δύο (2) φορές χρησιμοποιώντας α) τις τιμές των pixel των εικόνων (κανονικοποιημένες στο [0,1]) και β) τις τιμές των εικόνων που παράγει η τεχνική του dimensionality reduction.

OK!
 ΧΑΝΑΝΕ ΤΟ ΘΙ
ΛΟΝ Ο

Χρησιμοποιώντας τα αποτελέσματα, τις γραφικές παραστάσεις και εικόνες του κώδικα, καθώς και γραφικές παραστάσεις που θα φτιάξετε στο excel, θα συντάξετε μια έκθεση στην οποία θα παρουσιάζετε τα συμπεράσματά σας, θα κάνετε συγκριτικές αξιολογήσεις και θα προτείνετε ποιος είναι ο καλύτερος δυνατός συνδυασμός τεχνικών για την συγκεκριμένη περίπτωση.

Υπήρξε περίπτωση στην οποία ένας συνδυασμός πέτυχε τα καλύτερα αποτελέσματα σε όλες τις μετρικές;

οχι

Σημαντική παρατήρηση: Αξιολογείστε με βάση την αναφορά που θα παραδώσετε, εργασία που *δεν* συνοδεύεται από γραπτή αναφορά βαθμολογείται με 0.

Καταληκτική Ημερομηνία Παράδοσης: Παρασκευή 10 Ιανουαρίου 2025, 23:55

Προσοχή! Δεν θα δοθεί παράταση. Καταναίμετε προσεκτικά τις ώρες εργασίας σας.

Οδηγίες:

A. Οι εργασίες είναι σε ομάδες μέχρι τέσσερα (4) άτομα. Κάθε άτομο μπορεί να υποβάλει εργασία σε μία μόνο ομάδα κάθε φορά.

B. Οι εργασίες θα πρέπει να αναρτώνται στο eClass σε ένα αρχείο zip (όχι rar) εντός της προβλεπόμενης προθεσμίας. **Προσοχή:** Κάθε ομαδική εργασία θα υποβάλλεται μόνο από ένα μέλος της ομάδας (εσείς επιλέγετε ποιος/ποια).

Γ. Κάθε εργασία πρέπει να συνοδεύεται από:

- Ένα και μόνο ένα αρχείο .py θα περιέχει τις απαντήσεις στα ερωτήματα
- Μια **αναφορά** σε pdf με τα ακόλουθα στοιχεία:
 - ο Εξώφυλλο: 1 σελίδα, περιλαμβάνει τα στοιχεία των φοιτητών της ομάδας, όνομα μαθήματος, ημερομηνία, τμήμα και λοιπά σχετικά στοιχεία.
 - ο Συγκεντρωτικός πίνακας περιεχομένων, εικόνων, και λοιπών γραφημάτων που παραθέτετε στην αναφορά.
 - ο Ενότητα εισαγωγή: 1 σελίδα, περιγράφετε το πρόβλημα (*χωρίς* να αντιγράψετε αυτούσια την εκφώνηση της άσκησης)
 - ο Θεωρητικό υπόβαθρο: Μέθοδοι που εφαρμόστηκαν, από μέχρι 3 σελίδες, περιγράφετε τις μεθόδους που χρησιμοποιήσατε, εξηγώντας ποιες τιμές παραμέτρων (hyperparameters) επηρεάζουν την απόδοση και τι τιμές επιλέξατε εσείς για αυτές
 - ο Πειραματικά αποτελέσματα: Παραθέτετε τα σχετικά αποτελέσματα, μέχρι 5 σελίδες. Τα αποτελέσματα πρέπει να περιλαμβάνουν πίνακες, γραφικές παραστάσεις και εικόνες. Φροντίστε να υπάρχουν λεζάντες (captions) κάτω από κάθε γράφημα. Κάθε γραφική παράσταση πρέπει να συνοδεύεται από κείμενο που σχολιάζει τα αποτελέσματα.
 - ο Συμπεράσματα: 1 σελίδα, με βάση τα αποτελέσματα τι προτείνετε, ποιο μοντέλο αποδίδει καλύτερα, τι θα μπορούσε να γίνει για περαιτέρω βελτίωση στην απόδοση.

- Η αναφορά θα περιέχει γραφικές παραστάσεις κάθε είδους και πίνακες αξιολόγησης των αποτελεσμάτων που πρέπει να συνοδεύονται (έκαστο) από μια τουλάχιστον παράγραφο με σχολιασμό.

Φροντίστε ώστε:

- Ο κώδικας να συνοδεύεται απαραίτητως από κατάλληλα σχόλια.
- Να έχει γίνει συντακτικός και ορθογραφικός έλεγχος στην αναφορά που θα υποβάλετε.
- Οι προτάσεις να είναι κατανοητές και μικρές σε έκταση.
- Οι εικόνες να ***μην*** έχουν προκύψει από print screen. Αν το πρόγραμμα δημιουργεί μια εικόνα αποθηκεύστε την κανονικά (jpg ή png), πριν την χρησιμοποιήσετε.
- Οι γραφικές παραστάσεις να περιλαμβάνουν ονόματα στους άξονες και λεζάντα. Σκοπός είναι να γίνεται κατανοητό τι δείχνει, με μια ματιά.
- Αν κάτι δεν διευκρινίζεται, έχετε το δικαίωμα να κάνετε όποια υλοποίηση σας βολεύει. Φροντίστε να μπορείτε να εξηγήσετε τι ακριβώς κάνατε στον κώδικα.
- Οι βιβλιοθήκες που θα χρησιμοποιήσετε ***πρέπει*** να μπορούν να εγκατασταθούν μέσω του pip.
- Ο κώδικας ***πρέπει*** να τρέχει σε Google Colab.