

ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ

ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ



ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

2^η ΕΡΓΑΣΙΑ CLUSTERING

ΦΟΙΤΗΤΕΣ:

Κοκκινογένης Βασίλειος | ics21146

Κούβαρος Ιωάννης | iis22078

Μάνο Αστέριος-Πάρης | ics22088

Ιανουάριος, 2025

Πίνακας Περιεχομένων

Εισαγωγή	2
Θεωρητικό Υπόβαθρο.....	3
Μέθοδοι DR – Τεχνικές Clustering – Μετρικές Απόδοσης	3
Υπερπαράμετροι τεχνικών clustering.....	4
Πειραματικά Αποτελέσματα	6
Σύνολο Συγκριτικών Αποτελεσμάτων και Μετρικές Τεχνικών.....	10
Συμπεράσματα	13

Πίνακας Γραφημάτων και λοιπών Σχημάτων

Διάγραμμα 1: Original / Reconstructed Εικόνες τεχνικής SAE	6
Διάγραμμα 2: Ενδεικτικά αποτελέσματα clustering.....	6
Διάγραμμα 3: Διάγραμμα διασποράς της μεθόδου SAE.....	7
Διάγραμμα 4: Διάγραμμα διασποράς της μεθόδου Factor Analysis.....	8
Διάγραμμα 5: Διάγραμμα Αθροιστικής Εξηγούμενης Διακύμανσης (Cumulative Explained Variance Plot) μεθόδου PCA	9

Εισαγωγή

Η ανάλυση δεδομένων και η εφαρμογή τεχνικών μηχανικής μάθησης για την αναγνώριση δομών σε πολυδιάστατα δεδομένα αποτελεί μια σύγχρονη πρόκληση στον τομέα της μηχανικής μάθησης. Στο πλαίσιο αυτής της μελέτης, στόχος είναι να διερευνηθούν και να αξιολογηθούν διαφορετικοί συνδυασμοί τεχνικών μείωσης διάστασης (dimensionality reduction) και συσταδοποίησης (clustering) για την ομαδοποίηση εικόνων. Τα δεδομένα προέρχονται από το σύνολο fashion-mnist, το οποίο περιλαμβάνει εικόνες ενδυμάτων (λ.χ. t-shirt, sneaker και trousers) ταξινομημένες σε δέκα κατηγορίες/κλάσεις. Το πρόβλημα παρουσιάζει ιδιαίτερο ενδιαφέρον, καθώς η πολυπλοκότητα των δεδομένων και η υψηλή διάστασή τους δημιουργούν την ανάγκη για την εύρεση των κατάλληλων μεθόδων ανάλυσής τους.

Η μελέτη επικεντρώνεται στην εφαρμογή τεχνικών μείωσης διάστασης, όπως η Principal Component Analysis (PCA), η Stacked Autoencoder (SAE), καθώς και η Factor Analysis (FA). Παράλληλα, εφαρμόζονται αλγόριθμοι clustering και τελικός στόχος είναι η αξιολόγηση της απόδοσης αυτών των συνδυασμών μέσω συγκεκριμένων μετρικών, όπως η Calinski–Harabasz index, η Silhouette score κ.α. Ιδιαίτερη έμφαση θα δοθεί στην εύρεση του βέλτιστου συνδυασμού τεχνικών για την εν λόγω περίπτωση καθώς και στην πιθανή εύρεση ενός συνδυασμού που να πετυχαίνει τα βέλτιστα αποτελέσματα σε κάθε μετρική.

Στόχος της έρευνας δεν είναι μόνο η εύρεση του βέλτιστου τεχνικού συνδυασμού, αλλά και η παροχή μιας πλήρους τεκμηριωμένης και ερμηνεύσιμης ανάλυσης που να αναδεικνύει τις δυνατότητες και τους περιορισμούς των εφαρμοζόμενων τεχνικών, παρέχοντας χρήσιμες πληροφορίες για μελλοντική χρήση τους σε παρόμοια προβλήματα και σύνολα δεδομένων. Η ανάλυση των αποτελεσμάτων και η κατάλληλη οπτικοποίησή τους, υποδεικνύουν τον πλέον αποδοτικό συνδυασμό τεχνικών, ικανό να ανταποκριθεί στις απαιτήσεις που τίθενται από τα δεδομένα και τις συνθήκες του προβλήματος.

Θεωρητικό Υπόβαθρο

Μέθοδοι DR – Τεχνικές Clustering – Μετρικές Απόδοσης

Στην μελέτη εφαρμόστηκαν μέθοδοι μηχανικής μάθησης για την ταξινόμηση των fashion εικόνων σε κλάσεις και συγκεκριμένα έγινε χρήση των παρακάτω τεχνικών dimensionality reduction: 1) Principal Component Analysis (PCA), 2) Stacked Autoencoder (SAE), 3) Factor Analysis. Χρησιμοποιήθηκε το data set fashion-mnist το οποίο είναι διαθέσιμο από τον σύνδεσμο https://keras.io/api/datasets/fashion_mnist/.

Για την εφαρμογή της μεθόδου **Stacked AutoEncoder (SAE)**, σχεδιάστηκε ένα νευρωνικό δίκτυο που αποτελείται από έναν encoder (για τη μείωση των διαστάσεων) και έναν decoder (για την ανακατασκευή των δεδομένων). Κατά τη φάση του dimensionality reduction, απομονώθηκε το κομμάτι του encoder για να εξαχθούν τα δεδομένα σε χαμηλότερες διαστάσεις.

Η **Ανάλυση Παραγόντων (Factor Analysis)** αποτελεί μια πολυμεταβλητή στατιστική μέθοδο που χρησιμοποιείται για τη μείωση της διάστασης μεγάλων συνόλων δεδομένων και την κατανόηση της υποκείμενης δομής τους. Στόχος της μεθόδου είναι ο εντοπισμός λανθανόντων παραγόντων (factors), οι οποίοι εξηγούν τις συσχετίσεις μεταξύ των παρατηρούμενων μεταβλητών. Οι λανθάνοντες αυτοί παράγοντες θεωρούνται ότι αντιπροσωπεύουν κοινά χαρακτηριστικά ή κρυφές αιτίες που επηρεάζουν τις μεταβλητές του αρχικού συνόλου δεδομένων. Η Ανάλυση Παραγόντων βασίζεται στην παραδοχή ότι οι παρατηρούμενες μεταβλητές μπορούν να εκφραστούν ως γραμμικός συνδυασμός των λανθανόντων παραγόντων και ενός τυχαίου σφάλματος.

Στα δεδομένα εφαρμόστηκαν τεχνικές συσταδοποίησης (clustering) τόσο στα ακατέργαστα (raw) όσο και στα σύνθετα περιγραφικά χαρακτηριστικά (features) που προέκυψαν μέσω των τεχνικών dimensionality reduction. Οι τεχνικές clustering που χρησιμοποιήθηκαν είναι η Minibatch kmeans, η DBSCAN και η Agglomerative Clustering. Επιλέχθηκε η τεχνική **Agglomerative Clustering**, η οποία είναι μια ιεραρχική μέθοδος ομαδοποίησης που ξεκινά αντιμετωπίζοντας κάθε σημείο ως ξεχωριστή ομάδα και σταδιακά συγχωνεύει τις πιο κοντινές ομάδες, μέχρι να επιτευχθεί ο επιθυμητός αριθμός ομάδων. Στηρίζεται σε αποστάσεις ή ομοιότητες μεταξύ σημείων και παράγει ένα δενδροειδές διάγραμμα, το οποίο επιτρέπει την επιλογή του αριθμού ομάδων. Ενώ η τεχνική είναι ιδανική για την ανάλυση δομών δεδομένων, μπορεί παράλληλα να είναι υπολογιστικά απαιτητική για μεγάλα datasets λόγω της ανάγκης υπολογισμού αποστάσεων μεταξύ όλων των σημείων.

Για κάθε τεχνική clustering υπολογίστηκαν οι μετρικές Calinski–Harabasz index, Davies–Bouldin index, Silhouette score και η **Adjusted Mutual Analysis (AMI)** για την αξιολόγηση της απόδοσής τους. Η τελευταία επιλέχθηκε καθώς αποτελεί ένα στατιστικό μέτρο που χρησιμοποιείται για την αξιολόγηση της ομοιότητας μεταξύ δύο συνόλων ταξινομήσεων, λαμβάνοντας υπόψιν την πιθανότητα τυχαίας συμφωνίας. Πρόκειται για μια βελτιωμένη εκδοχή της Mutual Information (MI), η οποία διορθώνει το αποτέλεσμα βάσει του μεγέθους των δεδομένων και της κατανομής των κλάσεων, ώστε να παρέχει πιο ακριβή εκτίμηση της πραγματικής συσχέτισης. Η μετρική AMI κυμαίνεται σε τιμές μεταξύ -1 και 1, όπου: η τιμή 1 δηλώνει τέλεια συμφωνία μεταξύ των δύο ταξινομήσεων, η τιμή 0 υποδεικνύει ότι η ομοιότητα δεν είναι μεγαλύτερη από αυτή που θα προέκυπτε τυχαία και τέλος οι αρνητικές τιμές υποδεικνύουν χειρότερη απόδοση από την τυχαία συμφωνία και για αυτό τον λόγο εμφανίζονται σπάνια.

Υπερπαράμετροι τεχνικών clustering

Minibatch kmeans

Η τεχνική MiniBatch K-Means είναι μια παραλλαγή του K-Means που βελτιώνει την απόδοση σε μεγάλα σύνολα δεδομένων, καθώς λειτουργεί με μικρές τυχαίες υπο-ομάδες των δεδομένων (mini-batches) αντί για το πλήρες dataset. Οι παράμετροι που επηρεάζουν την απόδοση είναι οι `n_clusters`, που καθορίζει τον αριθμό των ομάδων (clusters) που θα δημιουργηθούν και κατά συνέπεια επηρεάζει άμεσα τη δομή των αποτελεσμάτων. Ακόμη η `random_state` χρησιμοποιείται για την αναπαραγωγικότητα των αποτελεσμάτων. Επιλέχθηκαν οι τιμές `n_clusters=10` με βάση την εκτίμηση ότι τα δεδομένα περιλαμβάνουν 10 ομάδες και η τιμή `random_state=42` ως τυπική (default) τιμή.

DBSCAN

Η τεχνική DBSCAN βασίζεται στην πυκνότητα των δεδομένων και εντοπίζει ομάδες που περιβάλλονται από περιοχές χαμηλής πυκνότητας, ενώ ταυτόχρονα χαρακτηρίζει ορισμένα δεδομένα ως "θόρυβο" (outliers). Οι παράμετροι που επηρεάζουν την απόδοση είναι αρχικά η `eps` που δηλώνει την μέγιστη απόσταση μεταξύ δύο σημείων ώστε να θεωρηθούν γειτονικά και επηρεάζει άμεσα τον αριθμό και το μέγεθος των clusters. Ακόμη, η `min_samples` που εκφράζει τον ελάχιστο αριθμό σημείων που απαιτούνται για να σχηματιστεί ένα cluster. Για τον καθορισμό των τιμών των παραμέτρων στις τεχνικές PCA και FA ορίστηκαν οι τιμές `eps = 3` και `min_samples = 5`, ενώ στην τεχνική SAE ήταν αναγκαία η μείωση του `eps` σε 0.1 και αύξηση του `min_samples` σε 15. Οι τιμές αυτές επιλέχθηκαν μετά από πολλές δοκιμές

ώστε να εντοπίζονται ομάδες με σχετικά στενή εγγύτητα στα δεδομένα και για να διασφαλιστεί ότι τα clusters περιλαμβάνουν τουλάχιστον 50 σημεία, περιορίζοντας την εμφάνιση μικρών ή μη χρήσιμων ομάδων. Στόχος ήταν να αυξηθεί ο αριθμός των παραγόμενων clusters.


Agglomerative Clustering

Η μετρική Agglomerative Clustering είναι μια ιεραρχική μέθοδος ομαδοποίησης που ξεκινά με κάθε σημείο ως ξεχωριστό cluster και σταδιακά συγχωνεύει τα πλησιέστερα clusters μέχρι να δημιουργηθεί ο επιθυμητός αριθμός ομάδων. Η παράμετρος που επηρεάζει την απόδοση είναι η `n_clusters` που δηλώνει τον τελικό αριθμό των clusters που θα δημιουργηθούν. Επιλέχθηκε η τιμή `n_clusters=10` για να συγκριθεί άμεσα με το αποτέλεσμα της μετρικής MiniBatch kmeans.

Πειραματικά Αποτελέσματα

Παρακάτω παρουσιάζουμε ενδεικτικά αποτελέσματα από τα cell κώδικα και γραφήματα από τη σύγκριση των τεχνικών dimensionality reduction στο excel.

4^ο Ερώτημα SAE: Αρχικές και Ανακατασκευασμένες Εικόνες




Διάγραμμα 1: Original / Reconstructed Εικόνες τεχνικής SAE

Παραπάνω παρουσιάζονται τυχαίες εικόνες από τη κάθε κλάση (ο έως 9) του dataset και οι αντίστοιχες ανακατασκευασμένες εικόνες με βάση την τεχνική SAE.

10^ο Ερώτημα PCA: Αποτελέσματα Clustering των MiniBatch και DBSCAN

Clustering Results for Selected Classes - MiniBatch KMeans


Clustering Results for Selected Classes - DBSCAN



Διάγραμμα 2: Ενδεικτικά αποτελέσματα clustering

Παραπάνω παρουσιάζονται ενδεικτικές τυχαίες εικόνες των τεχνικών clustering για τις πρώτες τέσσερις κατηγορίες.

5^ο Ερώτημα SAE: Dimensionality Reduction με την τεχνική SAE




Διάγραμμα 3: Διάγραμμα διασποράς της μεθόδου SAE

Η γραφική παράσταση απεικονίζει την οπτικοποίηση των δεδομένων έπειτα από την εφαρμογή της μεθόδου SAE. Στο διάγραμμα διατηρούνται οι δύο κύριες συνιστώσες της μειωμένης διάστασης που εξηγούν τις σημαντικότερες πληροφορίες των δεδομένων. Τα χρώματα των σημείων αντιστοιχούν στις διαφορετικές κατηγορίες, με ετικέτες από το 0 έως το 9 (λ.χ. T-shirt/top, Trouser, Ankle boot). Παρατηρείται ότι κάποιες κατηγορίες σχηματίζουν πιο διακριτά clusters (πυκνές περιοχές με ίδιο χρώμα), ενώ άλλες επικαλύπτονται.

Παρατήρηση: Κάθε διαφορετική εκτέλεση της τεχνικής SAE έχει ως αποτέλεσμα διαφορετική γραφική παράσταση καθώς και διαφορετικές επιδόσεις στις μετρικές αξιολόγησης του DBSCAN. Παρόλα αυτά διατηρείται κάθε φορά σωστή η αναλογία των αποτελεσμάτων, αφού παρατηρούνται μόνο μικρές αποκλίσεις.


5^ο Ερώτημα Factor Analysis: Dimensionality Reduction με την τεχνική Factor Analysis



Διάγραμμα 4: Διάγραμμα διασποράς της μεθόδου Factor Analysis

Η γραφική παράσταση απεικονίζει την οπτικοποίηση των δεδομένων με τη μέθοδο Factor Analysis. Παρουσιάζονται οι δύο κύριες συνιστώσες του μειωμένου χώρου και τα σημεία είναι χρωματισμένα σύμφωνα με την πραγματική κατηγορία των δεδομένων. Κάθε χρώμα αντιπροσωπεύει μία από τις δέκα κατηγορίες του dataset, με τις κατηγορίες να κυμαίνονται από το 0 έως το 9 (λ.χ. T-shirt/top, Trouser, Bag). Τα δεδομένα φαίνεται να σχηματίζουν clusters, ενώ παρατηρείται μερική επικάλυψη μεταξύ των κατηγοριών, γεγονός που υποδηλώνει παρόμοια χαρακτηριστικά σε ορισμένες κλάσεις.

5^ο Ερώτημα PCA: Dimensionality Reduction με την τεχνική PCA



Διάγραμμα 5: Διάγραμμα Αθροιστικής Εξηγούμενης Διακύμανσης (Cumulative Explained Variance Plot) μεθόδου PCA

Η γραφική παράσταση δείχνει τη σωρευτική εξηγούμενη διακύμανση σε σχέση με τον αριθμό των κύριων συνιστωσών (Principal Components). Στον κάθετο άξονα παρουσιάζεται το ποσοστό της σωρευτικής διακύμανσης που εξηγείται από τον αυξανόμενο αριθμό κύριων συνιστωσών ενώ στον οριζόντιο άξονα απεικονίζεται ο αριθμός των κύριων συνιστωσών που χρησιμοποιούνται. Η κόκκινη διακεκομμένη γραμμή αντιπροσωπεύει το όριο του 95% της εξηγούμενης διακύμανσης, που χρησιμοποιείται για να επιλεγεί ένας κατάλληλος αριθμός συνιστωσών. Η πράσινη διακεκομμένη γραμμή δείχνει τον αριθμό των συνιστωσών που απαιτούνται (187) για να φτάσει η σωρευτική διακύμανση το 95%.

Η καμπύλη δείχνει ότι οι πρώτες συνιστώσες εξηγούν τη μεγαλύτερη ποσότητα διακύμανσης, ενώ οι επόμενες συνεισφέρουν ολοένα και λιγότερο. Μετά από ένα σημείο, οι επιπλέον συνιστώσες έχουν πολύ μικρή συμβολή, κάτι που υποδηλώνει ότι η υψηλή διάσταση μπορεί να μειωθεί χωρίς να χαθεί σημαντική πληροφορία.

Η γραφική παράσταση είναι βασική για την επιλογή του αριθμού διαστάσεων που θα χρησιμοποιηθούν μετά την εφαρμογή της PCA. Η μείωση σε 187 συνιστώσες εξασφαλίζει ότι διατηρείται το 95% της συνολικής διακύμανσης.

Σύνολο Συγκριτικών Αποτελεσμάτων και Μετρικές Τεχνικών

Ο παρακάτω πίνακας δημιουργήθηκε με τη χρήση του excel και παρουσιάζει τις επιδόσεις τριών διαφορετικών τεχνικών clustering (MiniBatch KMeans, DBSCAN, Agglomerative Clustering) σε συνδυασμό με τρεις μεθόδους dimensionality reduction (PCA, SAE, Factor Analysis).

Παραδοχή: Για την σωστή σύγκριση των τεχνικών clustering εφαρμόστηκε η μέθοδος της βαθμολογίας των επιδόσεων όπου με 3 βαθμολογήθηκε η τεχνική με το καλύτερο σκορ, με 2 η μέτρια και με 1 η χειρότερη.

Χρησιμοποιήθηκαν οι εξής τέσσερις μετρικές:

1. Calinski–Harabasz index: Υψηλότερες τιμές υποδηλώνουν καλύτερη διαχωριστικότητα.
2. Davies–Bouldin index: Χαμηλότερες τιμές υποδηλώνουν καλύτερη συνολική ποιότητα clustering.
3. Silhouette score: Όσο πιο κοντά είναι οι τιμές στο 1, τόσο καλύτερη είναι η ποιότητα των clusters, καθώς δείχνουν ότι τα δεδομένα βρίσκονται κοντά στο κέντρο του cluster τους και μακριά από τα άλλα clusters.
4. Adjusted Mutual Information (AMI): Τιμές κοντά στο 1 αντανακλούν υψηλό βαθμό συσχέτισης μεταξύ προβλεπόμενων και αληθινών ετικετών.

PCA	MiniBatch KMeans	DBSCAN	Agglomerative Clustering
Calinski–Harabasz index	1350.768	50.653	1219.239
Davies–Bouldin index	1.985	1.624	2.001
Silhouette score	0.147	-0.328	0.126
Adjusted Mutual Information	0.500	0.248	0.552
Αξιολόγηση Μετρικών	3	1	2
3-καλύτερη	2	3	1
2-μέτρια	3	1	2
1-χειρότερη	2	1	3
SUM	10	6	8

SAE	MiniBatch KMeans	DBSCAN	Agglomerative Clustering
Calinski–Harabasz index	6378.1099	163.2433	5374.7471
Davies–Bouldin index	1.1970	1.7870	1.2786
Silhouette score	0.2754	-0.0284	0.2262
Adjusted Mutual Information	0.3460	0.0714	0.3632
Αξιολόγηση Μετρικών	3	1	2
3-καλύτερη	3	1	2
2-μέτρια	3	1	2
1-χειρότερη	2	1	3
SUM	11	4	9

Factor Analysis	MiniBatch KMeans	DBSCAN	Agglomerative Clustering
Calinski–Harabasz index	167.1347	19.2845	157.6714
Davies–Bouldin index	3.8264	1.4666	3.8831
Silhouette score	0.0322	-0.0632	0.0172
Adjusted Mutual Information	0.4281	0.3398	0.5445
Αξιολόγηση Μετρικών	3	1	2
3-καλύτερη	2	3	1
2-μέτρια	3	1	2
1-χειρότερη	2	1	3
SUM	10	6	8

FINAL SUM	31	16	25
-----------	----	----	----

1. MiniBatch KMeans

Η τεχνική PCA συγκέντρωσε συνολική βαθμολογία 10, παρουσιάζοντας υψηλές επιδόσεις στις μετρικές Calinski–Harabasz index (1,350.768) και Silhouette score (0.147), γεγονός που την καθιστά μια ισχυρή επιλογή. Επιπλέον, η AMI (0.500) θεωρείται ικανοποιητική, ενώ η Davies–Bouldin index (1.985) σημείωσε χαμηλότερη απόδοση. Από την άλλη πλευρά, η SAE διακρίθηκε με συνολική βαθμολογία 11, επιτυγχάνοντας τη μεγαλύτερη τιμή στην Calinski–Harabasz index (6378.1099) και υψηλή τιμή στην AMI (0.3460). Παρόλο που η Silhouette score (0.2754) ήταν επίσης ικανοποιητική, η Davies–Bouldin index (1.1970) δεν παρουσίασε αντίστοιχα καλές επιδόσεις. Τέλος, η Factor Analysis συγκέντρωσε συνολική βαθμολογία 10, με

απόδοση που χαρακτηρίζεται σταθερή αλλά όχι εξαιρετική στις περισσότερες μετρικές.

2. DBSCAN

Η τεχνική DBSCAN, στην μέθοδο DR: PCA, συγκέντρωσε συνολική βαθμολογία 4, παρουσιάζοντας χαμηλές επιδόσεις στις περισσότερες μετρικές. Ειδικότερα, η Calinski–Harabasz index (50.653) και η Silhouette score (-0.328) ήταν χαρακτηριστικά χαμηλές. Αντίστοιχα, με την εφαρμογή της SAE, η DBSCAN σημείωσε επίσης συνολική βαθμολογία 4. Παρόλο που υπήρξε μια μικρή βελτίωση στη Davies–Bouldin index (1.7870), η συνολική αξιολόγηση της μεθόδου παρέμεινε χαμηλή. Τέλος, με τη χρήση της Factor Analysis, η DBSCAN κατάφερε να επιτύχει ελαφρώς υψηλότερη συνολική βαθμολογία 6, με μια μικρή βελτίωση να παρατηρείται στην Calinski–Harabasz index (157.8714). Παρ’ όλα αυτά, η συνολική της απόδοση εξακολουθεί να είναι περιορισμένη.

3. Agglomerative Clustering

Η τεχνική Agglomerative Clustering, σε συνδυασμό με την PCA, συγκέντρωσε συνολική βαθμολογία 10, παρουσιάζοντας υψηλές επιδόσεις στις μετρικές AMI (0.552) και Silhouette score (0.126). Παρόμοια, η χρήση της SAE οδήγησε επίσης σε συνολική βαθμολογία 10, με μια ισορροπημένη απόδοση σε όλες τις μετρικές και την AMI (0.3632) να ξεχωρίζει ως η καλύτερη τιμή. Αντίθετα, με την Factor Analysis, η συνολική βαθμολογία έφτασε το 9, με την Calinski–Harabasz index (157.8714) και την AMI (0.5502) να επιδεικνύουν αξιοπρεπείς τιμές, αλλά οι υπόλοιπες μετρικές παρουσίασαν χαμηλή επίδοση, περιορίζοντας τη συνολική απόδοση της μεθόδου.

Συμπεράσματα

Η παρούσα μελέτη εστίασε στη διερεύνηση της απόδοσης διαφορετικών συνδυασμών τεχνικών μείωσης διάστασης (PCA, SAE, Factor Analysis) και clustering (MiniBatch KMeans, DBSCAN, Agglomerative Clustering) για την ομαδοποίηση δεδομένων υψηλής διάστασης από το σύνολο fashion-mnist. Η αξιολόγηση βασίστηκε σε τέσσερις μετρικές (Calinski–Harabasz index, Davies–Bouldin index, Silhouette score, Adjusted Mutual Information) και κατέδειξε σημαντικές διαφορές ανάμεσα στις τεχνικές.

Η MiniBatch KMeans εμφάνισε την καλύτερη συνολική βαθμολογία (31), κυρίως λόγω της υψηλής απόδοσής της στις περισσότερες μετρικές, όταν συνδυάστηκε με την SAE. Ειδικότερα, ο συνδυασμός αυτός πέτυχε τη μεγαλύτερη τιμή στην Calinski–Harabasz index (2,818.2908) και υψηλή AMI (0.493), γεγονός που τον καθιστά ιδανικό για clustering δεδομένων αυτού του είδους. Παρόμοια, η PCA σε συνδυασμό με το MiniBatch KMeans σημείωσε καλή απόδοση (συνολική βαθμολογία 10), αν και η Davies–Bouldin index παρουσίασε χαμηλότερη τιμή.

Αντίθετα, το DBSCAN σημείωσε τις χαμηλότερες συνολικές βαθμολογίες (16), ανεξαρτήτως τεχνικής μείωσης διάστασης. Οι τιμές στις μετρικές, όπως η Calinski–Harabasz index και η Silhouette score, ήταν κατά κανόνα χαμηλές, ενώ μόνο με τη Factor Analysis σημειώθηκε κάποια βελτίωση. Ωστόσο, η συνολική του απόδοση παραμένει περιορισμένη, υποδεικνύοντας ότι η τεχνική αυτή δεν είναι κατάλληλη για τα συγκεκριμένα δεδομένα.

Τέλος, η τεχνική Agglomerative Clustering σημείωσε καλή συνολική απόδοση (25), με την PCA και την SAE να οδηγούν σε βαθμολογίες 10 και ισορροπημένες επιδόσεις. Οι υψηλές τιμές στις μετρικές AMI και Silhouette score καταδεικνύουν την καταλληλότητα αυτής της τεχνικής, αν και με τη Factor Analysis οι επιδόσεις μειώθηκαν ελαφρώς.

Τελικά, ο συνδυασμός **MiniBatch KMeans με SAE αναδεικνύεται ως ο πλέον αποδοτικός για τη συγκεκριμένη περίπτωση**, πετυχαίνοντας τις υψηλότερες βαθμολογίες στις περισσότερες μετρικές. Ωστόσο, **δεν παρατηρήθηκε συνδυασμός που να αποδίδει άριστα σε όλες τις μετρικές**. Η μελέτη υποδεικνύει πως για βέλτιστη απόδοση είναι σημαντική η επιλογή τεχνικών που να ανταποκρίνονται καλύτερα στα χαρακτηριστικά των δεδομένων. Βελτιώσεις μπορούν να επιτευχθούν μέσω περαιτέρω προσαρμογής των παραμέτρων ή χρήσης συνδυαστικών προσεγγίσεων (ensemble methods).